

专利技术交底书

[撰写提示]

技术交底书，是向专利代理师提供发明技术的重要文件。为了让专利代理师更好地理解我们的发明技术，提高专利代理师撰写专利申请文件的质量和效率，需要**准确、全面、清晰、完整**地填写表格中的信息。

交底书模板中的示例仅供参考，技术方案的表达形式可以自由安排。

联系人信息			
技术联系人	唐丹丹	联系电话	18688738908
归属部门	AI 技术平台组	电子邮箱	tangdandan@sf-express.com

详细技术信息	
1、提案名称	一种基于性能指标的大模型 Endpoint 智能路由系统
2、背景技术	2.1 现有技术介绍（面向技术小白，请对现有/最接近的技术方案进行描述，包括本技术方案所处的技术领域、背景以及相关技术发展等） 在大模型 API 网关领域，当前大部分系统采用静态路由策略。 当模型服务发生性能波动或故障时（如推理延迟增加、可用性下降），系统无法自动、快速地进行故障转移，导致用户请求长时间访问故障模型，造成大量超时和错误。 现有技术的主要限制： ● 缺乏实时性能评估：无法根据实时性能指标进行动态决策 ● 无 Endpoint 级别策略：所有用户共享全局模型池，无法针对不同用户配置个性化策略 ● 故障转移效率低：从故障发生到恢复需要 5 分钟以上，期间大量请求受影响 ● 可观测性差：无完整的审计追踪和路由决策历史记录 ● 缺乏灵活干预：手动干预流程复杂，应急响应时间长（10 分钟以上） 2.2 现有技术的缺点或本发明解决的技术问题（项目/系统中存在什么样的技术问题需要提出改进，注意避免过分夸大现有技术的缺点） 本发明旨在通过实时性能指标驱动的智能路由系统，解决上述技术问题，实现： ● 秒级故障检测和转移（从 5 分钟降低到 30 秒） ● Endpoint 级别的灵活策略管理（支持多用户隔离和个性化配置） ● 多维度的健康评估（综合评估延迟、吞吐量、可用性等指标） ● 高效的手动干预能力（应急响应时间<5 秒，完整的审计追踪）
3、详细方案	3.1 本发明的核心发明点（请说明为了解决上述技术问题，你所设计、构思的技术方案中最关键的几个要素） 示例： 核心创新点 1：混合型三层路由策略

- 结合手动干预、Syncer 预计算和 Gateway 降级重算三个层级，在性能和实时性之间达到最优平衡
- Manual Override 层(优先级最高)支持立即生效的手动干预
- Syncer 预计算层(主方案,覆盖 99%场景)基于 30 秒周期的 Prometheus 指标预计算,保证一致性和可观测性
- Gateway 降级重算层(降级方案,覆盖 1%场景)基于缓存指标进行实时计算


核心创新点 2: 基于性能指标的多维度健康评估模型

- 采用 Prometheus 指标(TTFT 延迟、TPOT 延迟、Availability 可用性)进行实时评估
- 支持定制化阈值: 每个 Endpoint 可配置不同的告警阈值
- 分级健康状态评估: healthy(所有指标正常) → degraded(部分指标异常) → unhealthy(多指标异常或不可用)
- 相比单一指标评估,多维度评估能更准确地捕捉各种类型的故障

核心创新点 3: 支持多策略的策略模式框架

- 采用策略模式 (Strategy Pattern) 设计,支持 Fallback(多级兜底)、LoadBalance(负载均衡)、Canary(灰度发布)、QoS(服务质量)等多种路由策略
- 新增策略无需修改核心代码,通过策略接口实现即可
- 支持策略链评估和组合,提供高度的可扩展性

3.2 完整技术方案描述 (设想面向技术小白时,如何结合图示对技术方案进行详细、通俗的解释)



系统分为 4 层架构:

应用层: 提供 Endpoint CRUD API、策略管理 API、手动干预 API 等;

接入层: 完全兼容 OpenAI 范式,用户只需要将原来配置的模型名称替换为 Endpoint ID

即可无缝切换，然后享受到自动故障转移、灰度发布等重要功能；


决策层：

实时采集私部署和商业模型性能指标并进行健康度打分；

根据实时健康度智能切换 Endpoint 对应的路由策略；

旁路鉴权服务根据路由策略中的权重基于加权随机算法实现流量精确分配；

缓存层：构建本地缓存+redis 分布式缓存两层缓存系统，达到 80%本地缓存命中率，对性能影响微乎其微；



同时，控制面与请求面分离：

控制面：新增 Endpoint、对接监控自动切换、手动覆盖等复杂逻辑均在控制面完成，最终都只影响路由策略表；

请求面：旁路鉴权服务中识别到用户是根据 Endpoint 访问的，则只需要读取最终的路由策略表，然后根据策略进行负载均衡到正确的大模型服务；

3.3 技术效果

效果 1：故障转移速度提升 10 倍

- 现有技术：故障发生到完成转移需要 5 分钟以上（依赖人工干预）
- 本发明：自动检测到转移完成只需 30 秒（Syncer 30 秒周期 + 决策执行 <3 秒）
- 提升倍数：10 倍

效果 2：用户体验显著改善

- 故障对用户的影响时间从 5 分钟以上降低到 30 秒以内
- 用户系统故障时间大幅缩短，系统可用率相应提升
- 故障投诉率下降

	效果 3：运维成本大幅降低 ● 人工干预频率从每周 3-5 次降低到每月 1-2 次（下降 90%） ● 应急响应时间从 10 分钟降低到<5 秒（提升 120 倍） ● 人工工作负荷减少 60% 效果 4：支持灵活的多用户隔离和个性化策略 ● 每个 Endpoint 可独立配置主模型、兜底模型和健康检查阈值 ● 不同用户的故障互不影响 ● 支持针对不同业务场景的定制化策略 效果 5：完整的可观测性和审计追踪 ● 所有路由决策都被记录在数据库中，可追踪 ● 所有手动干预都被审计，包含操作人、操作时间、操作内容 ● 支持通过 Dashboard 实时查看路由状态和历史决策
4、技术补充	4.1 替代方案（为了防止他人通过改变技术方案来绕开本发明，建议充分考虑其他可能的技术方案，如有则填写） 方案 1：特征识别和评估替代方式 除了使用 Prometheus 指标，还可以考虑： ● 基于业务层面的错误率指标（而非仅 TTFT/TPOT） ● 基于用户反馈的质量评分（主观评估） ● 基于成本的模型选择（选择最便宜的可用模型） ● 基于用户满意度的动态权重调整 方案 2：流量分配策略替代方式 除了 degraded 时的固定流量分配，还可以考虑： ● 根据恢复趋势动态调整分配比例（如果恢复快可提高验证流量） ● 分时段不同的分配策略（如高峰期 vs 低峰期） ● 基于损失函数优化的最优分配 ● A/B 测试框架用于对比不同模型 方案 3：策略框架替代方式 除了当前支持的 5 种策略，还可以扩展： ● 基于用户身份的路由（VIP 用户优先使用主模型） ● 基于请求内容的路由（长请求和短请求用不同模型） ● 基于时间的路由（高峰期和低峰期用不同模型） ● 混合策略（多个策略组合评估）



	4.2 术语说明（请对本交底书中提及的关键术语、技术缩略语进行解释说明，如果有英文缩写，请给出英文全称和中文注释，若有英文单词，请给出中文注释或者解释） 示例： Endpoint: 端点，代表一个用户/项目的模型服务配置，包括主模型、兜底模型和健康检查阈值； TTFT: Time To First Token，首次令牌延迟，指从发送请求到收到第一个输出令牌的时间； TPOT: Time Per Output Token，指连续输出令牌之间的平均间隔 Availability: 可用性，指成功请求数占总请求数的比例 Override: 干预，人工手动改变路由决策的操作 Fallback: 兜底，当主模型出现故障时使用的备用模型 Health Status: 健康状态，包括 healthy(健康)、degraded(降级)、unhealthy(不健康) Traffic Allocation: 流量分配，指将请求分配给不同模型的比例 4.3 参考文献（对于理解交底书中的技术方案有帮助的专利/论文/期刊/网页，如有则填写） ● Prometheus 官方文档：https://prometheus.io/docs/ ● Google SRE Book：https://sre.google/books/ ● Kubernetes 官方文档：https://kubernetes.io/docs/
5、技术声明	5.1 本发明是否已经或计划在项目/产品中实施？（如果是，请列出相关的项目/产品名称、实施或计划实施的时间；并对项目/产品的研发背景做简要介绍） ☐ 属于技术研发成果，未应用到实际产品中； ☒ 该方案已应用到实际产品，产品在公司内部应用； ☐ 该方案确定应用到实际产品，将要或已经对外公开应用； ☐ 不属于技术研发成果，未应用到实际产品中。 示例： 项目名称：AI 技术平台； 产品名称：模型广场接入点管理； 计划实施时间：2025 年 11 月-2025 年 12 月。 产品介绍：模型广场项目是 AI 技术平台为大模型推理服务提供的一站式 API 网关平台。该平台为企业用户提供稳定、高效、可靠的大模型（LLM）API 访问服务，接入点功能支持多模型聚合、动态路由、故障转移、灰度发布等高级功能。 该产品已在公司多个部门进行内部试点应用，包括 AI 平台智能客服系统等。本发明的 Endpoint 智能路由系统是该产品的核心创新功能，通过实时性能指标驱动的动态路由，显著提升系统的可用性和用户体验。 5.2 本发明是否已经或计划对外公开？（如果是，请说明公开渠道、公开或计划公开的时间；公开渠道可以是展会、技术宣讲、和供应商沟通、发表文章等）

暂无对外公开计划，仅限于内部使用。

[技术交底书自查指引]

1、准确：

- 1.1 为便于技术沟通，请确保联系电话和电子邮箱填写准确；
- 1.2 为避免信息传达遗漏，技术联系人和知识产权系统的提案人应为同一人，请勿代为提交专利提案；
- 1.3 为防模板中的信息干扰，请删除交底书模板中的示例。

2、全面：

- 2.1 为便于他人能够理解技术方案与实际产品之间的关联关系，请确保技术信息涵盖发明技术对应实际产品的介绍。

3、清晰：

- 3.1 为避免他人理解错误，请确保技术方案通俗明了、专有名词定义清晰；具体有：方法流程图需体现数据流向和步骤顺序；同一对象的前后描述应保持统一，英文词汇需补充解释。

4、完整：

- 4.1 为确保技术方案充分公开，请提供足够的信息来完整披露发明技术，并使得他人能够实施该技术；
- 4.2 不确定是否属于技术秘密的部分可高亮/批注，并提示知识产权法务评估。

